

Univerzitet : Univerzitet u Novom Sadu

Fakultet: Fakultet tehničkih nauka

Predmet: Softverski algoritmi u sistemima automatskog upravljanja

**PREDVIĐANJE ISHODA UTAKMICA
SVETSKOG PRVENSTVA
PRIMENOM METODA MAŠINSKOG UČENJA**

Autor:

Milica Marković RA 193/2023

Mentor:

Emina Demirović

Novi Sad, jun 2026.

UVOD.....	2
OPIS PROBLEMA.....	3
SKUP PODATAKA.....	4
PREPROCESIRANJE PODATAKA.....	5
KREIRANJE ATRIBUTA	6
Elo rejting reprezentacija	7
Forma reprezentacija	7
Međusobni susreti reprezentacija.....	8
Kodiranje faze takmičenja.....	8
EKSPLORATORNA ANALIZA PODATAKA(EDA)	9
TRENING MODELA	11
PODEŠAVANJE HIPERPARAMETARA	12
ANALIZA MODELA I REZULTATI.....	13
Analiza konfuzione matrice	14
Značaj atributa.....	15
OPIS APLIKACIJE I UPUTSTVO ZA KORISNIKA.....	16
ZAKLJUČAK.....	18

UVOD

- Fudbal predstavlja jedan od najpopularnijih sportova na svetu, a Svetsko prvenstvo najznačajnije međunarodno takmičenje. Uprkos velikoj količini statističkih podataka i analiza koje su danas dostupne, predviđanje ishoda fudbalskih utakmica i dalje predstavlja veoma izazovan zadatak. Razlog za to je veliki broj faktora koji mogu uticati na konačan rezultat, kao i činjenica da sport često donosi neočekivane događaje.
- Istorija Svetskih prvenstava pruža brojne primere koji potvrđuju ovu nepredvidivost. Jedan od najpoznatijih primera dogodio se 2014. godine, kada je reprezentacija Nemačke u polufinalu savladala domaći Brazil rezultatom 7:1. Takođe, na tok utakmice mogu uticati i faktori koje je teško ili gotovo nemoguće predvideti. Poznat primer predstavlja četvrtfinale Svetskog prvenstva 1986. godine između Argentine i Engleske, kada je Dijego Maradona postigao gol rukom koji zbog sudijske greške nije poništen. Ovakvi događaji pokazuju da na ishod utakmice ne utiču samo kvalitet timova i statistički pokazatelji, već i okolnosti koje nije moguće u potpunosti modelovati.
- Razvojem metoda mašinskog učenja otvorena je mogućnost analize velikih količina sportskih podataka i pronalaženja obrazaca koji mogu pomoći pri proceni verovatnoće različitih ishoda utakmica. Iako nije moguće potpuno eliminisati neizvesnost koja postoji u sportu, primena savremenih algoritama omogućava donošenje objektivnijih i preciznijih procena zasnovanih na istorijskim podacima.

OPIS PROBLEMA

- Predmet ovog projekta jeste razvoj modela mašinskog učenja za predviđanje ishoda utakmica Svetskog prvenstva. Problem je formulisan kao zadatak višeklasne klasifikacije, pri čemu model za svaku utakmicu predviđa jednu od tri moguće klase:
 - pobeda domaće reprezentacije
 - nerešen rezultat
 - pobeda gostujuće reprezentacije
- Za donošenje predikcije koriste se podaci koji opisuju reprezentacije pre odigravanja utakmice. Poseban izazov predstavlja činjenica da na rezultat utiče veliki broj međusobno povezanih faktora, dok deo njih nije moguće direktno izmeriti ili uključiti u model.
- Dodatni problem predstavlja predviđanje nerešenih rezultata. U poređenju sa pobedama domaće ili gostujuće reprezentacije, nerešeni ishodi se javljaju ređe, zbog čega ih modeli mašinskog učenja teže prepoznaju. Zbog toga prilikom evaluacije nije dovoljno posmatrati samo ukupnu tačnost modela, već i njegovu sposobnost prepoznavanja svake pojedinačne klase.
- Za rešavanje ovog problema korišćeni su istorijski podaci sa utakmica Svetskog prvenstva, kao i podaci o međunarodnim utakmicama reprezentacija na osnovu kojih su izračunati Elo rejtingi. Pored toga, kreirani su atributi koji opisuju trenutnu formu reprezentacija, njihove međusobne susrete i fazu takmičenja. Na osnovu pripremljenih podataka trenirano je i

upoređeno više modela mašinskog učenja, nakon čega je izabran model sa najuravnoteženijim performansama.

- Kao završni deo projekta razvijena je interaktivna aplikacija koja omogućava korisniku unos podataka o reprezentacijama i prikaz predikcije ishoda utakmice.

SKUP PODATAKA

- Za realizaciju projekta korišćena su dva skupa podataka. Prvi skup sadrži istorijske podatke o utakmicama Svetskog prvenstva, uključujući reprezentacije učesnice, postignute golove, fazu takmičenja i konačan ishod utakmice. Ovi podaci predstavljaju osnovu za formiranje ciljane promenljive i treniranje modela mašinskog učenja.
- Drugi skup podataka obuhvata međunarodne utakmice reprezentacija i korišćen je za procenu njihove relativne snage. Na osnovu ovih podataka izračunati su Elo rejtingi timova, koji predstavljaju numerički pokazatelj kvaliteta reprezentacije zasnovan na prethodnim rezultatima.
- Prvobitno je razmatrano korišćenje FIFA rang liste kao jednog od pokazatelja kvaliteta reprezentacija. Međutim, analizom podataka utvrđeno je da FIFA rangiranje nije dostupno za veliki broj starijih utakmica obuhvaćenih skupom podataka, budući da je uvedeno znatno kasnije od početka posmatranog perioda. Kao posledica toga javlja se veliki broj nedostajućih vrednosti, što bi značajno smanjilo količinu dostupnih podataka za treniranje modela. Zbog toga je odlučeno da se umesto FIFA rangiranja koristi Elo rejting, koji omogućava znatno bolju pokrivenost podataka i dosledniju procenu snage reprezentacija tokom celog posmatranog perioda.

- Originalni skup podataka o utakmicama Svetskog prvenstva sadrži 1248 utakmica i 37 atributa. Nisu svi dostupni atributi pogodni za predviđanje ishoda budućih utakmica, pa je izvršena analiza i selekcija promenljivih koje mogu imati značajan uticaj na rezultat meča.
- Prilikom izbora atributa zadržane su samo informacije koje su poznate pre početka utakmice i koje mogu doprineti proceni očekivanog ishoda. Kao osnovni atributi izdvojeni su nazivi domaće i gostujuće reprezentacije (*home_team_name* i *away_team_name*), faza takmičenja (*stage*), naziv takmičenja (*tournament_name*) i ishod utakmice (*result*).
- Atributi koji sadrže informacije poznate tek nakon završetka utakmice, kao što su broj postignutih golova ili druge izvedene statistike zasnovane na konačnom rezultatu, nisu korišćeni kao ulazne promenljive jer bi doveli do curenja informacija (data leakage) i nerealno visokih performansi modela.
- Kombinovanjem podataka iz oba izvora formiran je jedinstven skup podataka koji predstavlja osnovu za dalju obradu i kreiranje novih karakteristika u okviru faze kreiranja atributa (feature engineering).

PREPROCESIRANJE PODATAKA

- Nakon formiranja početnog skupa podataka izvršeno je preprocesiranje sa ciljem pripreme podataka za kreiranje novih atributa i treniranje modela mašinskog učenja.
- Najpre je izvršena provera nedostajućih vrednosti. Tokom analize ustanovljeno je da bi atributi povezani sa FIFA rangiranjem sadržali veliki broj nedostajućih podataka zbog ograničene dostupnosti istorijskih FIFA rang lista. Kako bi se izbegao značajan gubitak podataka, ovi atributi nisu korišćeni u daljoj obradi, već je kao pokazatelj kvaliteta reprezentacija korišćen Elo rejting.
- Nakon toga izvršena je provera dupliranih zapisa. Analizom nije utvrđeno postojanje duplikata koji bi mogli negativno uticati na proces treniranja modela.
- Kategorijski atributi pripremljeni su za dalju obradu odgovarajućim enkodiranjem. Faza takmičenja transformisana je u numerički oblik, dok su nazivi reprezentacija kodirani

korišćenjem Label Encoder metode. Na taj način omogućeno je korišćenje ovih atributa u algoritmima mašinskog učenja.

- Po završetku preprocesiranja formiran je skup podataka pogodan za kreiranje novih atributa koji opisuju kvalitet reprezentacija, njihovu formu i međusobne susrete.

KREIRANJE ATRIBUTA

- Originalni skup podataka sadrži osnovne informacije o utakmicama, međutim ovakvi podaci nisu dovoljni da opišu trenutnu snagu reprezentacija i okolnosti u kojima se utakmica igra. Zbog toga je izvršeno kreiranje novih atributa sa ciljem da se modelu pruže dodatne informacije koje mogu doprineti preciznijem predviđanju ishoda.

Elo rejting reprezentacija

- Jedan od najznačajnijih atributa predstavlja Elo rejting reprezentacija. Elo sistem je prvobitno razvijen za rangiranje šahista, ali se danas uspešno primenjuje i u sportu za procenu relativne snage timova.
- Prvobitno je razmatrano korišćenje FIFA rang liste kao pokazatelja kvaliteta reprezentacija. Međutim, FIFA rangiranje uvedeno je tek tokom devedesetih godina, zbog čega veliki broj starijih utakmica nema dostupne podatke o plasmanu reprezentacija. To bi dovelo do značajnog broja nedostajućih vrednosti

- Zbog toga je odlučeno da se Elo rejting izračuna samostalno korišćenjem kompletnog skupa međunarodnih utakmica reprezentacija počev od 1872. godine. Na ovaj način za svaku reprezentaciju postoji procena kvaliteta u trenutku odigravanja posmatrane utakmice.

- Elo rejting ažurira se nakon svake utakmice prema formuli:

$$\text{Elo}_{\text{novi}} = \text{Elo}_{\text{stari}} + K \cdot (S - E)$$

K određuje brzinu promene rejtinga, S stvarni rezultat utakmice, E očekivani rezultat izračunat na osnovu trenutnih rejtinga timova.

- Prilikom računanja očekivanog ishoda uključen je i faktor prednosti domaćeg terena. Za svaku utakmicu određeni su Elo rejting domaće i gostujuće reprezentacije, nakon čega je kreiran atribut *fifa_rank_diff* koji predstavlja razliku njihovih Elo rejtinga. Pozitivne vrednosti ukazuju na prednost domaće ekipe, dok negativne vrednosti označavaju jaču gostujuću reprezentaciju.

Forma reprezentacija

- Pored ukupnog kvaliteta tima, značajnu ulogu može imati i njegova trenutna forma. Zbog toga su kreirani atributi koji opisuju efikasnost reprezentacija neposredno pre odigravanja utakmice.
- Najpre je za svaku reprezentaciju izračunata forma na samom turniru. Forma je definisana kao prosečan broj postignutih golova u poslednje tri prethodno odigrane utakmice iste reprezentacije na posmatranom takmičenju. Ukoliko reprezentacija pre posmatrane utakmice nije odigrala nijedan meč, vrednost forme postavlja se na nulu.
- Tokom razvoja projekta razmatrano je korišćenje poslednje tri i poslednjih pet utakmica. Eksperimentalnim testiranjem utvrđeno je da korišćenje tri utakmice daje bolje rezultate, jer starije utakmice imaju manji značaj za procenu trenutne forme reprezentacije.
- Pored forme ostvarene na turniru, uključene su i prijateljske utakmice. Za svaku reprezentaciju izračunat je prosečan broj postignutih golova u poslednje tri prijateljske utakmice. Konačna forma definisana je kao ponderisana kombinacija:

$$\text{Forma} = 0.7 \times \text{turnirska forma} + 0.3 \times \text{forma iz prijateljskih utakmica}$$

- Veća težina dodeljena je utakmicama na samom turniru jer predstavljaju relevantniji pokazatelj kvaliteta reprezentacije usled većeg takmičarskog značaja i jače konkurencije.

Prijateljske utakmice korišćene su kao dopunski izvor informacija o trenutnoj efikasnosti ekipe. Na ovaj način dobijeni su atributi *home_form_total* i *away_form_total*.

Međusobni susreti reprezentacija


- Kako istorija međusobnih duela može sadržati korisne informacije o odnosu dve reprezentacije, kreiran je atribut *head_to_head*.
- Za svaku utakmicu analizirani su svi prethodni međusobni susreti dve reprezentacije odigrani pre datuma posmatrane utakmice. Atribut predstavlja ukupan broj pobeda koje je domaća reprezentacija ostvarila protiv trenutnog protivnika. Na ovaj način model dobija dodatnu informaciju o istorijskom uspehu jednog tima protiv drugog, što nije obuhvaćeno Elo rejtingom niti pokazateljima forme.

Kodiranje faze takmičenja


- Faza takmičenja predstavlja kategorijski atribut koji opisuje značaj utakmice u okviru turnira. Kako algoritmi mašinskog učenja ne mogu direktno da rade sa tekstualnim vrednostima, izvršeno je numeričko kodiranje ovog atributa.
- Prilikom kodiranja poštovan je redosled napredovanja kroz takmičenje. Grupna faza dobila je najnižu vrednost, zatim osmina finala, četvrtfinale, polufinale, utakmica za treće mesto i finale. Na taj način model dobija dodatnu informaciju o važnosti utakmice i nivou pritiska pod kojim reprezentacije nastupaju.
- Nakon kreiranja svih navedenih atributa formiran je konačni skup podataka koji je korišćen za eksploratornu analizu, treniranje i evaluaciju modela mašinskog učenja.

EKSPLORATORNA ANALIZA PODATAKA(EDA)


- Pre treniranja modela sprovedena je eksploratorna analiza sa ciljem ispitivanja međusobnih zavisnosti atributa i prisustva ekstremnih vrednosti koje bi mogle uticati na stabilnost modela.



- Izračunata je korelaciona matrica numeričkih atributa. Analizom nije utvrđeno postojanje jakih korelacija ($|r| > 0.7$) između parova atributa, što ukazuje da ne postoji izražena multikolinearnost i da svaki atribut nosi relativno nezavisnu informaciju.
- Detekcija ekstremnih vrednosti sprovedena je IQR metodom. Najveći broj ekstremnih vrednosti detektovan je kod atributa head_to_head, dok je kod atributa koji opisuju formu i Elo razliku broj ekstremnih vrednosti znatno manji.



- Analizom je utvrđeno da detektovane ekstremne vrednosti ne predstavljaju greške u podacima, već realne situacije: kod head_to_head, najveći broj parova reprezentacija se prvi put sreće na Svetskom prvenstvu, dok mali broj reprezentacija sa dugom istorijom susreta (Brazil i Argentina) prirodno odstupa od ove vrednosti. Ekstremne vrednosti kod Elo razlike i forme odgovaraju utakmicama sa izrazitom razlikom u kvalitetu reprezentacija, što predstavlja koristan signal za model, a ne grešku. Iz tog razloga, nijedna vrednost nije uklonjena iz skupa podataka.



- Pored toga, ispitana je i raspodela ciljne promenljive. Utvrđeno je da je skup podataka neuravnotežen: pobede domaće reprezentacije čine najveći deo uzorka, dok su nerešeni

rezultati znatno ređi. Ova neuravnoteženost je uzeta u obzir prilikom treniranja i evaluacije modela.

TRENING MODELA

- Skup podataka podeljen je na trening i test podskup u odnosu 80:20, uz stratifikaciju prema ciljnoj promenljivoj, kako bi raspodela klasa u oba podskupa ostala reprezentativna.
- Razmatrana je i podela podataka prema godinama održavanja prvenstva, čime bi se simuliralo predviđanje budućih turnira na osnovu istorijskih podataka. Međutim, zbog malog broja utakmica po pojedinačnim prvenstvima takav pristup dovodi do značajno neuravnoteženih trening i test skupova. Na primer, izbor prvenstva iz 2018. godine kao test skupa rezultovao bi premalim brojem test primera, dok bi korišćenje starijih prvenstava dovelo do prevelikog test skupa. Zbog toga je za potrebe ovog rada primenjena stratifikovana slučajna podela podataka u odnosu 80:20.
- Numerički atributi standardizovani su korišćenjem StandardScaler transformacije. Standardizacija je izvršena samo nad numeričkim atributima, pri čemu je svaki atribut transformisan tako da ima srednju vrednost približno jednaku nuli i standardnu devijaciju približno jednaku jedinici. Ovaj korak posebno je značajan za logističku regresiju, dok kod stabala odlučivanja i ansambl metoda nema značajan uticaj na performanse.
- Isprobano je i upoređeno više algoritama za klasifikaciju: logistička regresija, stablo odlučivanja, Random Forest i XGBoost. Cilj je bio uporediti modele različite složenosti - od jednostavnog linearnog modela do ansambl metoda i odabrati onaj koji najbolje balansira tačnost i sposobnost prepoznavanja svih klasa, posebno nerešenih ishoda.
- Modeli su prvo trenirani sa podrazumevanim (default) parametrima, kako bi se dobio početni uvid u njihove performanse pre bilo kakvog podešavanja. Pokazalo se da pojedini modeli, iako sa relativno visokom ukupnom tačnošću, potpuno izostavljaju klasu nerešenog ishoda (odziv 0%), zbog neuravnoteženosti klasa u skupu podataka. Ovo je ukazalo na potrebu za dodatnim podešavanjem, ne samo modela, već i kriterijuma po kome se ocenjuje njegov kvalitet.

	Model	Accuracy	Draw Precision	Draw Recall	Draw F1	Home Recall	Away Recall
Logistic Regression		0.620	0.000000	0.000000	0.000000	0.886525	0.447761
Decision Tree		0.524	0.250000	0.238095	0.243902	0.659574	0.417910
Random Forest		0.568	0.287671	0.500000	0.365217	0.595745	0.552239
XGBoost		0.604	0.416667	0.119048	0.185185	0.829787	0.432836

PODEŠAVANJE HIPERPARAMETARA

- Nakon evaluacije osnovnih modela sprovedena je optimizacija hiperparametara sa ciljem poboljšanja performansi modela, posebno u prepoznavanju nerešenih ishoda. U početnoj fazi korišćen je Grid Search pristup, kojim su sistematski ispitivane različite kombinacije hiperparametara za odabrane modele.
- Međutim, pokazalo se da optimizacija zasnovana isključivo na standardnim metrikama, poput ukupne tačnosti, ne dovodi nužno do boljeg prepoznavanja nerešenih rezultata. Zbog toga je, pored automatske pretrage, sprovedeno i ručno podešavanje hiperparametara na osnovu detaljne analize rezultata i klasifikacionih izveštaja.
- Kod logističke regresije poseban fokus stavljen je na podešavanje težina klasa (class weights), kako bi se ublažio problem neuravnoteženosti podataka. Ispitano je više vrednosti težine za klasu nerešenog ishoda, nakon čega je odabrana konfiguracija koja pruža najbolji odnos između ukupne tačnosti i uspešnosti prepoznavanja nerešenih utakmica.
- Kod Random Forest modela analiziran je uticaj broja stabala, maksimalne dubine stabala i minimalnog broja uzoraka potrebnog za grananje čvora. Na osnovu dobijenih rezultata odabrana je konfiguracija koja ostvaruje najuravnoteženije performanse između sve tri klase. Odabrana je konfiguracija sa `n_estimators=150`, `max_depth=12`, `min_samples_split=2`, `class_weight='balanced'` nakon ispitivanja svih kombinacija.
- Konačni izbor modela nije zasnovan isključivo na ukupnoj tačnosti, već i na sposobnosti modela da prepozna sve klase, sa posebnim naglaskom na nerešene ishode koji predstavljaju najzahtevniju klasu za klasifikaciju.

Accuracy: 61.20%				
Classification Report:				
	precision	recall	f1-score	support
away_win	0.54	0.57	0.55	67
draw	0.35	0.40	0.38	42
home_win	0.74	0.70	0.72	141
accuracy			0.61	250
macro avg	0.55	0.56	0.55	250
weighted avg	0.62	0.61	0.62	250


ANALIZA MODELA I REZULTATI

- Pre interpretacije rezultata važno je napomenuti da predviđanje ishoda fudbalskih utakmica predstavlja problem za koji i savremeni modeli u naučnoj literaturi najčešće ostvaruju tačnost između približno 55% i 65%, čak i kada koriste znatno veće količine podataka i složenije modele. Prema opštem iskustvu u ovoj oblasti, modeli za predikciju fudbalskih ishoda retko prelaze 60-65% tačnosti.
- Nakon treniranja modela i optimizacije hiperparametara izvršena je evaluacija njihovih performansi na test skupu podataka. Za procenu kvaliteta modela korišćene su standardne metrike klasifikacije: tačnost (accuracy), preciznost (precision), odziv (recall) i F1 mera.
- Posebna pažnja posvećena je uspešnosti prepoznavanja nerešenih rezultata. Tokom eksploratorne analize utvrđeno je da su nerešeni ishodi najmanje zastupljena klasa u skupu podataka, zbog čega predstavljaju najveći izazov za modele mašinskog učenja.
- Analizom dobijenih rezultata može se uočiti da ukupna tačnost nije dovoljna za procenu kvaliteta modela. Pojedini modeli ostvaruju relativno visoku tačnost zahvaljujući dobrom prepoznavanju dominantnih klasa, ali pri tome veoma loše klasifikuju nerešene utakmice.
- Kod logističke regresije uočeno je da model ostvaruje visoku tačnost, ali pokazuje ograničenu sposobnost prepoznavanja nerešenih rezultata. Iako je podešavanjem težina klasa postignuto određeno poboljšanje, model i dalje pokazuje tendenciju favorizovanja pobjeda jedne od reprezentacija.

- Model stabla odlučivanja ostvario je nižu ukupnu tačnost, ali je uspevao da prepozna deo nerešenih utakmica. Međutim, zbog izraženije varijabilnosti i sklonosti prenaučivosti, njegove performanse nisu bile dovoljno stabilne.
- XGBoost je ostvario konkurentne rezultate u pogledu ukupne tačnosti, ali se pokazalo da model teže prepoznaje nerešene ishode. To potvrđuje da visoka tačnost ne mora nužno značiti i ravnomerno uspešno klasifikovanje svih klasa.
- Najuravnoteženije performanse ostvario je Random Forest model. Iako njegova ukupna tačnost nije bila najveća, pokazao je najbolji balans između prepoznavanja pobeda domaće reprezentacije, pobeda gostujuće reprezentacije i nerešenih rezultata. Upravo zbog toga izabran je kao konačni model za implementaciju u aplikaciji.

Analiza konfuzione matrice


- Radi detaljnijeg uvida u ponašanje modela analizirana je konfuziona matrica konačnog modela.



- Konfuziona matrica omogućava pregled tačno i netačno klasifikovanih primera za svaku klasu. Može se uočiti da model najuspešnije prepoznaje pobeđe domaće reprezentacije, što je očekivano s obzirom na njihovu najveću zastupljenost u skupu podataka.
- Najveći broj grešaka javlja se kod nerešenih rezultata, koji se često klasifikuju kao pobeđa domaćina ili pobeđa gosta. Ovo je očekivana posledica neuravnoteženosti podataka, ali i činjenice da nerešeni ishodi često predstavljaju granične slučajeve između ostale dve klase.
- Uprkos tome, konačni model uspeva da prepozna značajan broj nerešenih utakmica, što predstavlja važno poboljšanje u odnosu na pojedine modele koji ovu klasu gotovo u potpunosti zanemaruju.

Značaj atributa

- Pored analize performansi modela, ispitana je i relativna važnost atributa korišćenih za donošenje odluke.




- Rezultati pokazuju da najveći uticaj na predikciju imaju atributi povezani sa kvalitetom i trenutnom formom reprezentacija. Posebno se izdvaja Elo razlika između timova, što je očekivano jer predstavlja direktan pokazatelj relativne snage reprezentacija.
- Značajan doprinos imaju i atributi koji opisuju formu timova na osnovu prethodnih nastupa, dok atribut međusobnih susreta ima nešto manji uticaj na konačnu odluku modela. Faza

takmičenja takođe doprinosi predikciji, ali u manjoj meri u odnosu na pokazatelje kvaliteta i forme reprezentacija.

- Tokom razvoja modela ispitana je i mogućnost smanjenja broja atributa korišćenjem samo tri ili pet najznačajnijih promenljivih prema rezultatima analize značaja atributa. Međutim, takav pristup nije doveo do poboljšanja performansi modela. Naprotiv, uočeno je blago smanjenje tačnosti i slabije prepoznavanje pojedinih klasa. Razlog za to je činjenica da atributi u modelu imaju sličan doprinos predikciji, pa uklanjanjem manje rangiranih dolazi do gubitka korisnih informacija. Iako pojedini atributi imaju nešto veći značaj od ostalih, nijedan od njih nije dovoljno dominantan da bi samostalno nosio najveći deo prediktivne moći modela. Zbog toga je kao konačno rešenje zadržan skup svih kreiranih atributa.
- Finalno odabrani model se izvozi za korišćenje u aplikaciji.

OPIS APLIKACIJE I UPUTSTVO ZA KORISNIKA

- Pored razvoja modela mašinskog učenja implementirana je i interaktivna aplikacija koja omogućava jednostavno korišćenje razvijenog sistema za predviđanje ishoda utakmica Svetskog prvenstva. Aplikacija je realizovana korišćenjem Streamlit okruženja i pruža grafički interfejs prilagođen korisnicima bez potrebe za poznavanjem detalja implementacije modela.
- Na početnoj stranici korisnik bira domaću i gostujuću reprezentaciju iz ponuđenih lista, kao i fazu takmičenja u kojoj se utakmica odigrava. Pored toga, omogućen je unos očekivanog broja golova domaće i gostujuće reprezentacije, koji se koriste za dodatnu analizu i prikaz informacija korisniku.

The image shows a web application interface for predicting football match outcomes. At the top, the text "SP 2026" is displayed in a large, teal, stylized font. Below it, the subtitle "Predviđanje ishoda utakmice" (Prediction of match outcome) is centered. The interface is divided into several sections: 1. "DOMAĆIN" (Home) and "GOST" (Away) sections, each with a dropdown menu. The Home dropdown is currently set to "Algeria" and the Away dropdown is set to "Belgium". 2. "FAZA TAKMIČENJA" (Match phase) section with a dropdown menu set to "Grupna faza" (Group phase). 3. "GOLOVI DOMAĆINA" (Home goals) and "GOLOVI GOSTA" (Away goals) sections. The Home goals input is set to "0" and the Away goals input is set to "2". Both inputs have minus and plus buttons for adjustment. 4. A large teal button at the bottom labeled "PREDVIDI ISHOD" (Predict outcome). The background of the interface is a dark, atmospheric image of a football stadium at night with lights and a cloudy sky.

- Nakon pokretanja predikcije, aplikacija automatski izračunava sve atribute potrebne modelu, uključujući formu domaće i gostujuće reprezentacije, broj prethodnih međusobnih pobjeda domaćina (head-to-head) i Elo razliku između timova. Na taj način korisnik nije u obavezi da ručno unosi vrednosti atributa korišćenih tokom treniranja modela.
- Posebna pažnja posvećena je validaciji unosa podataka. Ukoliko korisnik odabere istu reprezentaciju kao domaćina i gosta, aplikacija prikazuje odgovarajuću poruku o grešci i onemogućava izvršavanje predikcije, jer utakmica između identičnih timova nije validan scenario.
- Nakon uspešne obrade podataka, aplikacija prikazuje izračunate parametre utakmice, predviđeni ishod i procenjene verovatnoće za svaku od tri moguće klase.
- Pored konačne predikcije, korisniku su dostupne i verovatnoće svih ishoda, što omogućava bolji uvid u sigurnost modela i poređenje različitih scenarija.



- Razvijena aplikacija predstavlja praktičnu demonstraciju primene modela mašinskog učenja i omogućava brzo testiranje različitih kombinacija reprezentacija i faza takmičenja kroz jednostavan i intuitivan korisnički interfejs.

ZAKLJUČAK

- Rezultati dobijeni u okviru ovog projekta pokazali su da je moguće uspešno primeniti metode mašinskog učenja za predviđanje ishoda utakmica Svetskog prvenstva, uprkos

izraženoj neizvesnosti koja karakteriše sportska takmičenja. Poseban izazov predstavljalo je predviđanje nerešenih rezultata, zbog njihove manje zastupljenosti u podacima i složenosti faktora koji do njih dovode. Ipak, odabrani model ostvario je zadovoljavajuće i uravnotežene performanse na sve tri klase ishoda.

- Prostor za dalje unapređenje sistema postoji kroz uključivanje dodatnih informacija koje nisu bile dostupne u okviru ovog projekta. To se pre svega odnosi na vremenske i klimatske uslove tokom utakmice, povrede i izostanke igrača, individualne statistike fudbalera, karakteristike i iskustvo selektora, kao i druge faktore koji mogu uticati na rezultat meča. Takođe, moguće je ispitati primenu naprednijih modela i većih skupova podataka kako bi se procenio njihov doprinos tačnosti predviđanja.
- Ipak, imajući u vidu dostupne podatke, ograničenja problema i rezultate dobijene tokom eksperimentisanja sa različitim atributima i modelima, može se zaključiti da predstavljeno rešenje pruža dobar balans između tačnosti, interpretabilnosti i praktične primenljivosti. Dobijeni model i razvijena aplikacija uspešno ostvaruju postavljeni cilj projekta i predstavljaju kvalitetnu osnovu za buduća istraživanja u oblasti sportske analitike.